Carl FLEREAU

ETUDE DU PRIX DES VOITURES SPORTIVES

IAE
PARIS-EST

2023-2024

MASTER DATA ANALYST

Table of
CONTENTS

Introduction

I.Description de la base de données
1)Ou et quoi ?
2)Les variables
3)Nettoyage de la base

II.Analyse descriptive
1)Analyse Univarié et multivarié

III.Inférence statistique
1)Test d'indépendance (Khi^2)
2)Régression linéaire simple
3Régression linéaire multiple

Conclusion

Dans notre époque, ou l’offre sur le marché automobile ne cesse de croitre, un segment de ce marché m’intéresse particulièrement et mériterait qu’on y prête plus attention. Il s’agit du segment des voitures sportives. En effet, nombreux sont les passionnés d’automobile comme moi, qui ne se limitent pas à regarder la Formule 1 à la télé, et sont désireux de se faire plaisir en achetant un véhicule dit « sportif ». Une voiture dites « sportive » est un véhicule automobile conçu pour offrir des performances élevées, une maniabilité exceptionnelle et une expérience de conduite dynamique. Il faut très souvent, selon l’efficacité recherchée, débourser beaucoup pour acheter un véhicule de ce type. C’est dans ce cadre que nous allons dans cette étude, analyser quelques caractéristiques déterminantes dans le prix d’une voiture de sport. Cette étude a pour but de permettre à un constructeur souhaitant se lancer sur ce marché, de connaitre la manière dont certaines caractéristiques influeront sur le prix de vente. Elle a également pour but de permettre à un acheteur de comprendre comment le prix des véhicules de sport est fixé.

I. Description de la base de données

1. Ou et quoi ?

La base de données que j'ai choisis d'étudier s'intitule « Sports Car Prices dataset » et se trouve sur Kaggle. Cette base de données recense des véhicules de sport lancés entre 1965 et 2023, en nous indiquant la taille, le couple et la puissance du moteur, la durée pour passer de 0 à 60 MPH et le prix. Elle recense 1007 voitures.

Car Make	Car Model	Year	Engine Size (L)	Horsepower	Torque (lb-ft)	0-60 MPH Time (seconds)	Price (in USD)
Porsche	911	2022	3	379	331	4	101200
Lamborghini	Huracan	2021	5.2	630	443	2.8	274390
Ferrari	488 GTB	2022	3.9	661	561	3	333750
Audi	R8	2022	5.2	562	406	3.2	142700
McLaren	720S	2021	4	710	568	2.7	298000
BMW	M8	2022	4.4	617	553	3.1	130000
Mercedes-Benz	AMG GT	2021	4	523	494	3.8	118500
Chevrolet	Corvette	2021	6.2	490	465	2.8	59900
Ford	Mustang Shelby GT500	2022	5.2	760	625	3.5	81000
Nissan	GT-R Nismo	2021	3.8	600	481	2.5	212000

2. Les variables

-La variable « Car Make » désigne le constructeur automobile. Par exemple, Porsche, Audi ou Lamborghini qui sont très connus.
-La variable « Car Model » désigne le modèle de la voiture, il faudra surtout faire attention à cette variable car plusieurs modèles reviennent soit à cause d'un changement de prix, soit à une amélioration.
-La variable « Year » nous informe sur l'année de sortie du véhicule.
-La variable « Engine Size » nous indique la taille du moteur en litres. La cylindrée d'un moteur définit le volume total de tous les cylindres.
-La variable « Horsepower » fait référence à la puissance du véhicule en chevaux. La puissance est une spécification importante dont les acheteurs doivent tenir compte, car elle est directement liée à la vitesse de pointe et à la performance.
-La variable « Torque » désigne le couple moteur en lb-ft, pour un véhicule donné, un moteur qui dispose d'une puissance et d'un couple plus élevés offrira des accélérations plus rapides. C'est donc un élément que les acheteurs doivent aussi prendre en compte lors de l'achat d'un véhicule de sport.

-La variable « 0-60 MPH Time » nous indique le temps qu'un véhicule met pour passer de 0 à 60 Miles par heure.
-Enfin, la variable « Price » donne le prix du véhicule en $.

3.Nettoyage de la base

Dans le cadre de mon étude, il a fallut faire attention lors de l'importation de la base, aux véhicules avec certaines informations manquantes. Notamment sur la puissance en chevaux ou le prix.
J'ai également du supprimer les véhicules dans le but d'uniformiser la variable « Horsepower ».
Pour finir, certains véhicules apparaissaient plusieurs fois avec seulement une légère différence de prix, j'ai donc éliminé les véhicules identiques à un autre sur un certains nombre de colonnes.

II-Analyse descriptive

1)Analyse univarié et multivariés

Les constructeurs

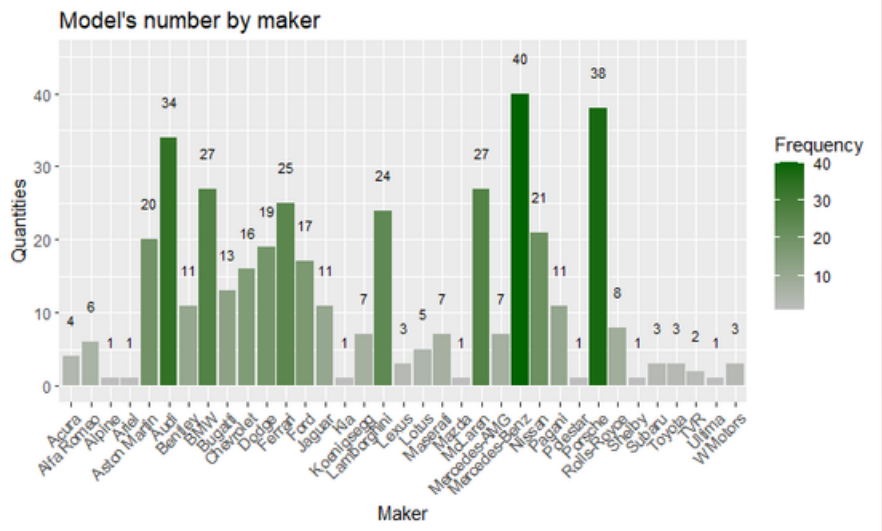

Après avoir nettoyé la base, nous avons donc 35 constructeurs se partageant 419 véhicules. Ce partage n'est en aucun cas équitable comme nous pouvons le voir, il y a une majorité de véhicules des marques Audi, Mercedes-Benz et Porsche.

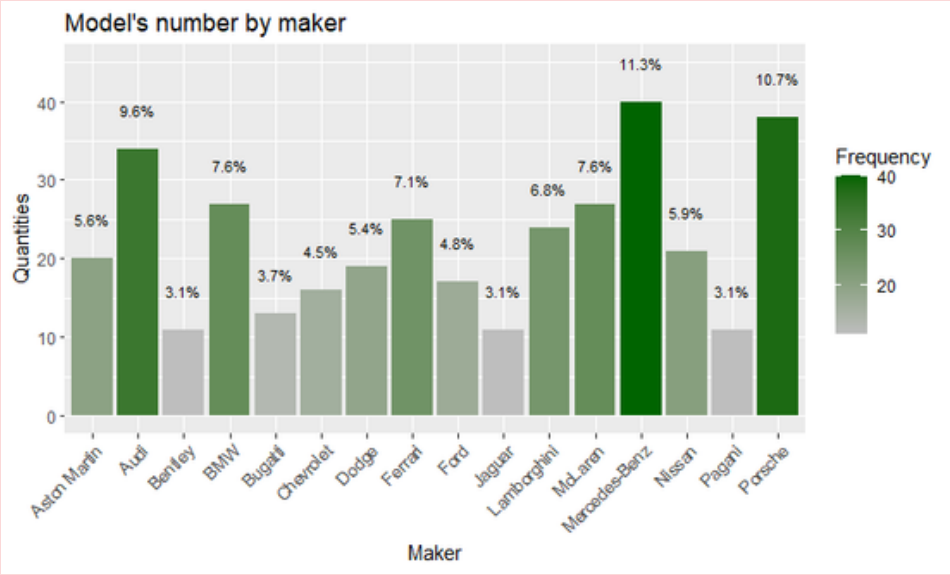


```
> sum(sort((prop.table(Model_by_makers1)*100), decreasing = TRUE)[1:3])
[1] 31.63842
```

En effet, les 3 principaux constructeurs dans la base représente 31.64% des véhicules. Cela peut s'expliquer par le fait que ce sont des constructeurs allemands, connus pour la fiabilité et la performance de leurs véhicules.

Car Make	num_vehicles	min_price	max_price	avg_price
factor	integer	numeric	numeric	numeric
Audi	34	52,500	183,300	92,524.7
BMW	27	50,000	147,500	76,917.8
Ferrari	25	215,000	625,000	280,226.8
McLaren	27	192,500	2,300,000	406,920.0
Mercedes-Benz	40	50,000	335,000	159,133.9
Porsche	38	58,900	1,800,000	149,592.1
n: 6				

D'après ce tableau, parmi les 6 principaux constructeurs, les voitures les moins chers se trouvent chez BMW et les plus chers chez McLaren. Une personne cherchant à acheter son premier véhicule de sport, et souhaitant commencer par une marque connue peut donc s'orienter vers une BMW, une McLaren, mais également un de ces autres constructeurs, cela dépendra de son budget.

Le Prix

Il est important pour se positionner en tant que constructeur, mais également en tant qu'acheteur, de connaitre la distribution des prix sur le marché. En effet, on ne négocie pas sans connaitre les prix moyens.
Dans notre base, il y a une grande partie des véhicules qui se vendent à un prix inférieur à 500000$. Mais comme nous pouvons le voir sur le premier graphique, Il existe également des véhicules destinés à une clientèle aisée.
Ceci explique également le prix moyen des véhicule de la base qui se voit tiré vers le haut pour atteindre 418105$. Il est plus pertinent d'analyser les quantiles qui permettent de se faire une idée des tendances sur le marché.

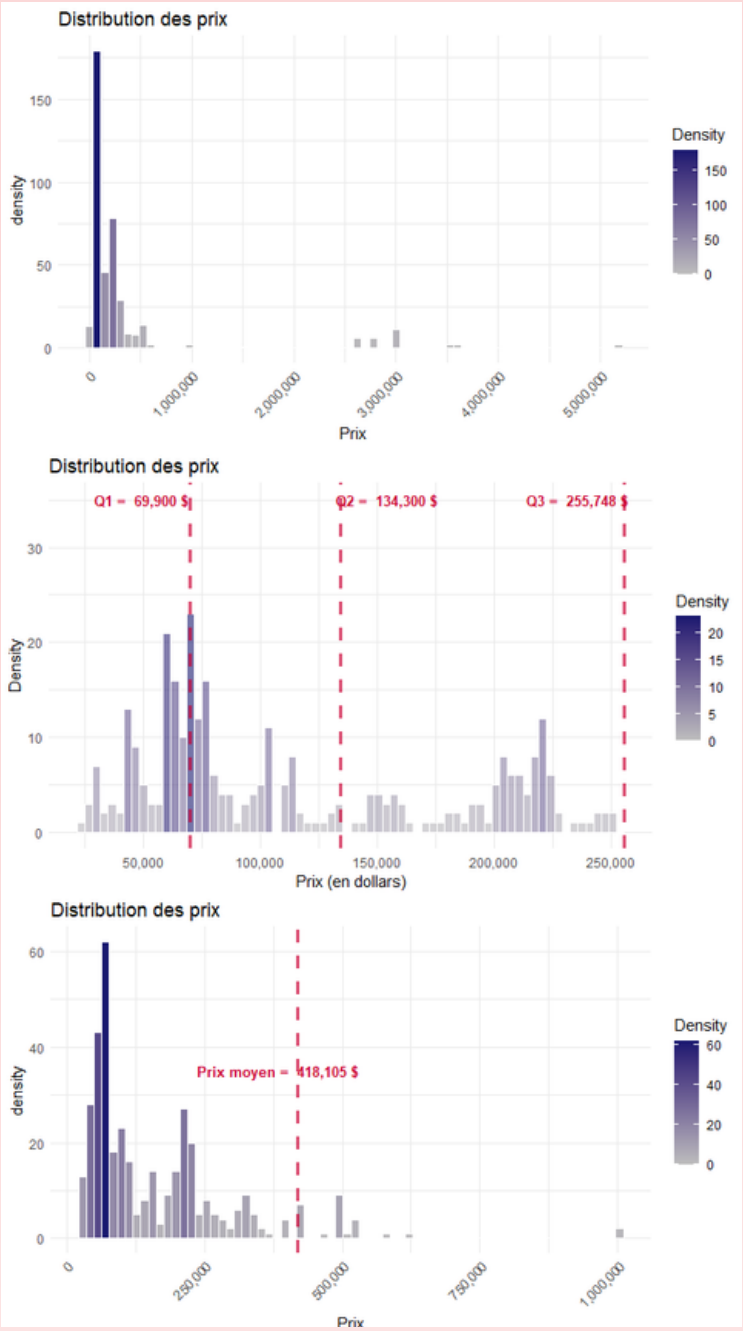

La puissance

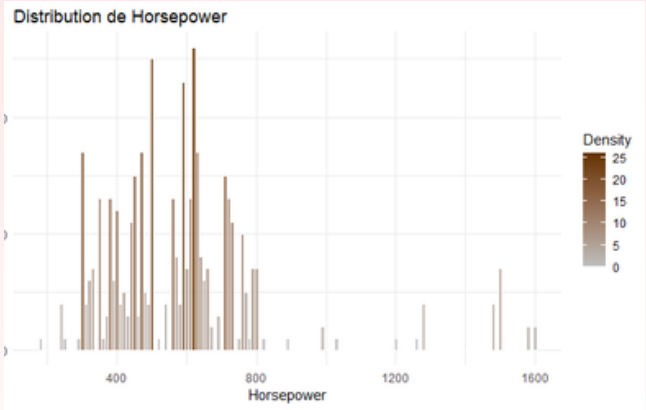

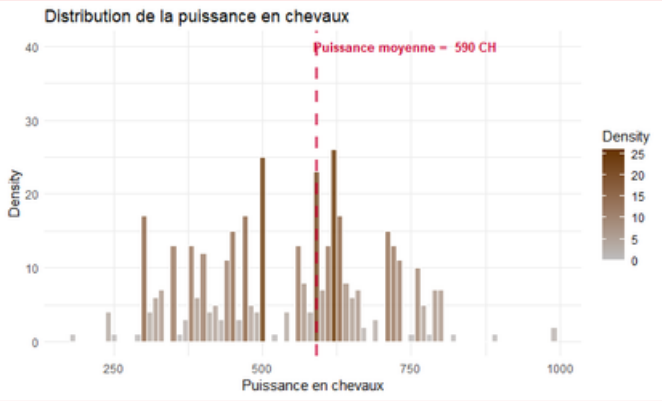

Nous nous retrouvons dans une situation similaire au niveau de la puissance, car il existe des véhicules très puissants comme la bugatti Chiron qui atteint les 1600 chevaux, mais une grande majorité des véhicules ont moins de 700 chevaux. Ce qui est déjà beaucoup même pour une voiture de sport. Pour une personne n'ayant pas l'habitude de ce type de véhicule se satisfera très bien d'un véhicule à 250 chevaux.

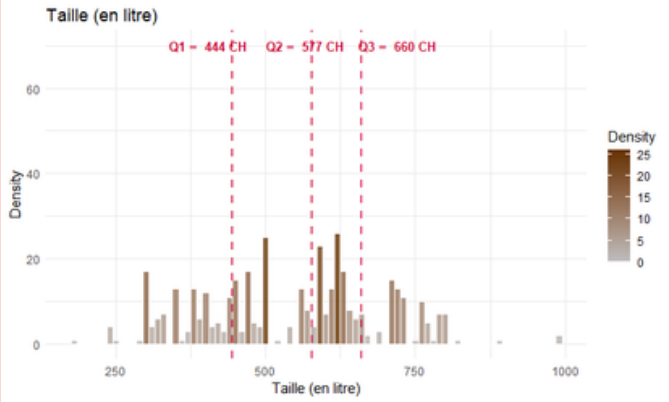

Car Make	num_vehicles	min_Horsepower	max_Horsepower	avg_Horsepower
factor	integer	numeric	numeric	numeric
Audi	34	349	591	497.3
BMW	27	255	617	458.0
Ferrari	25	591	986	676.5
McLaren	27	562	1,035	642.3
Mercedes-Benz	40	382	730	553.5
Porsche	38	300	887	431.6

n: 6

Pour les principaux constructeurs, on peut voir que Ferrari et McLaren produisent les véhicules les plus puissants avec une moyenne de puissance pour leurs véhicules de respectivement, 676,5 CH et 642,3 CH.

La taille du moteur

La taille du moteur est en moyenne de 4,4 L, avec une forte concentration des véhicules autour de la moyenne. La taille du moteur est une caractéristiques assez complexe à prendre en compte car elle accompagne les autres caractéristiques comme la puissance et le couple. Il est donc intéressant d'avoir une grosse cylindrée car elle s'accompagnera souvent d'un couple et d'une puissance élevés.

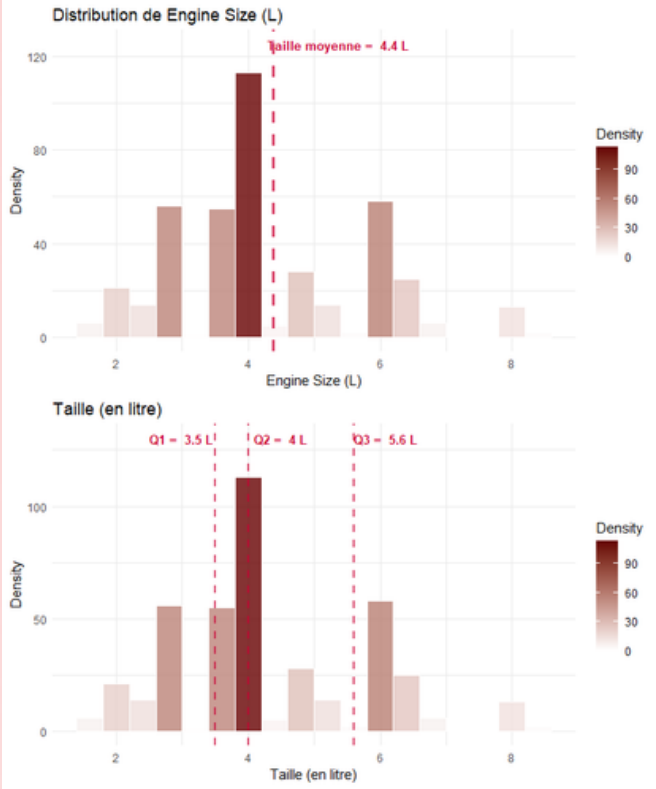

Car Make	num_vehicles	min_Size	max_Size	avg_Size
factor	integer	numeric	numeric	numeric
Audi	34	2.5	5.2	3.4
BMW	27	1.5	4.4	3.1
Ferrari	25	3.9	6.5	4.1
McLaren	27	3.0	4.0	3.8
Mercedes-Benz	40	2.0	6.3	4.5
Porsche	38	2.0	4.6	3.0

n: 6

On voit ici, que les moteurs Porsche semblent avoir une assez faible cylindrée, ce qui peut s'expliquer par l'idée que moins de cylindre permet de moins consommer. Donc une personne ayant tout de même un certain attrait pour l'écologie pourra opter pour un véhicule Porsche.

Le Temps au 0-60 MPH

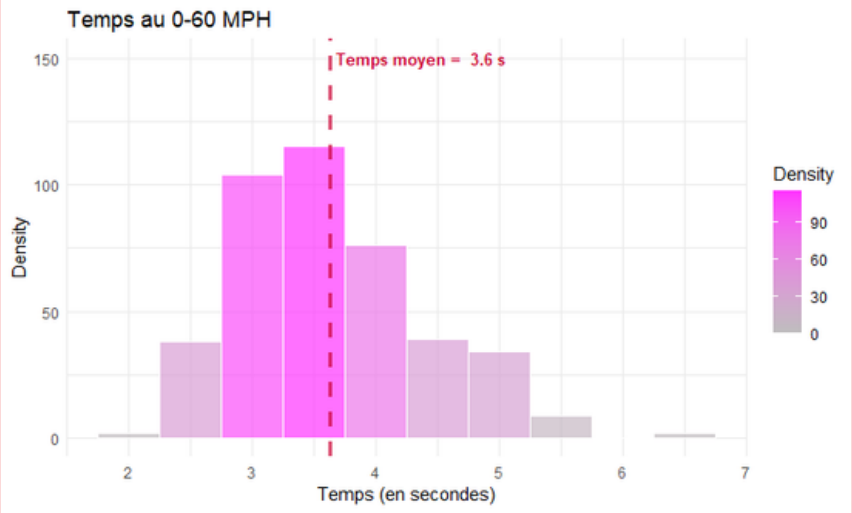

C'est une caractéristique très intéressante que nous avons ici, le temps pour passer de 0 à 60 Miles par heure. Cela donne une idée assez claire sur la rapidité du démarrage après un feu rouge notamment. Il est connu, que les forces de l'ordre doivent avoir des véhicules rapides au démarrage par exemple d'où l'importance d'avoir un véhicule plus rapide que la moyenne.

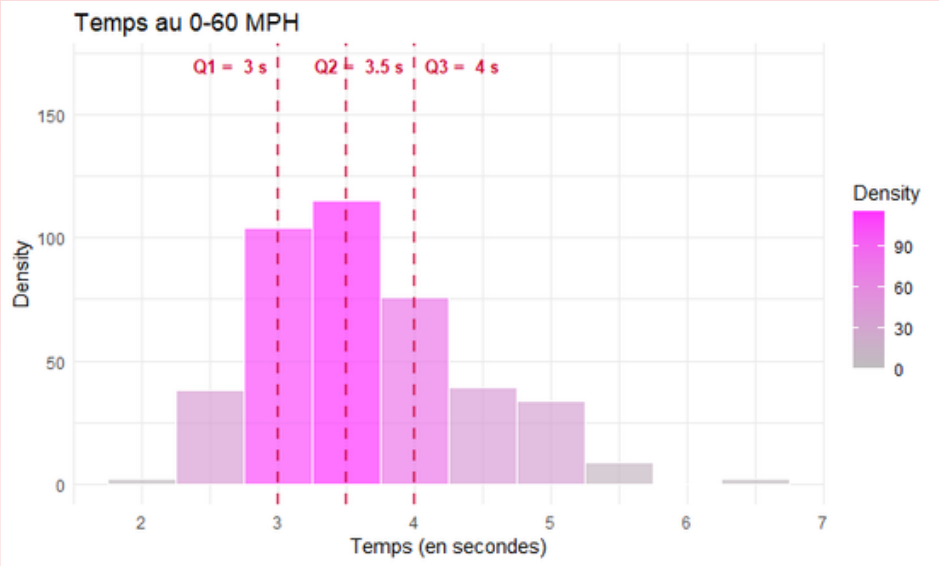

Car Make	num_vehicles	min_Time	max_Time	avg_Time
factor	integer	numeric	numeric	numeric
Audi	34	3.1	4.4	3.5
BMW	27	3.1	5.2	3.9
Ferrari	25	2.5	3.5	3.1
McLaren	27	2.5	3.2	2.9
Mercedes-Benz	40	2.9	4.9	3.7
Porsche	38	2.2	5.4	4.2

n: 6

Il est pas surprenant de voir Ferrari et McLaren afficher les moyennes de temps les plus faibles. Ces 2 constructeurs sont connu pour concevoir des véhicules de course. Pour une variable aussi concrète, il serait intéressant de vérifier d'autres caractéristiques comme le poids par exemple.

Le Couple

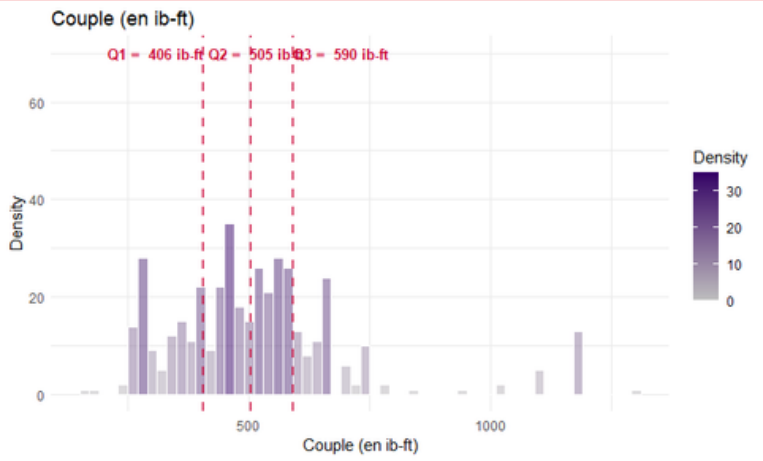

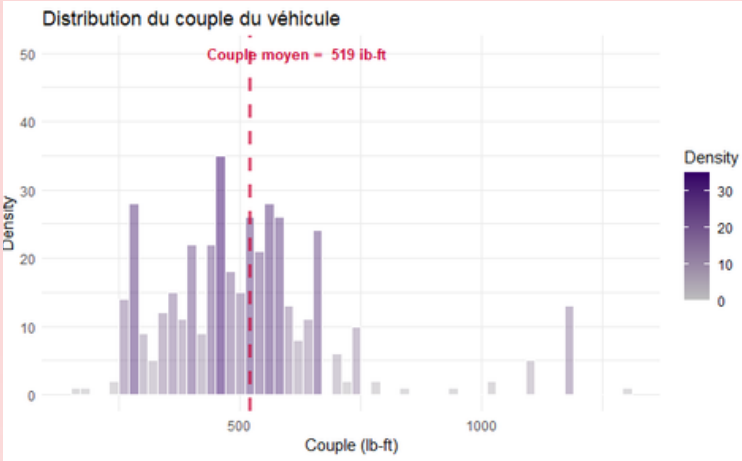

Car Make	num_vehicles	min_Torque	max_Torque	avg_Torque
factor	integer	numeric	numeric	numeric
Audi	34	354	590	479.1
BMW	27	184	553	420.8
Ferrari	25	413	590	550.4
McLaren	27	443	848	498.2
Mercedes-Benz	40	354	664	504.7
Porsche	38	254	944	397.1
n: 6				

Pour finir, notre dernière variable désigne le couple qui donne une indication sur la capacité d'accélération du véhicule. C'est donc également une variable à prendre en compte sérieusement. Le couple moyen de notre base est de 519 lb-ft et la plupart des véhicules se concentrent autour de ce niveau là. C'est le cas aussi pour nos principaux constructeurs.

III-Inférence Statistique

1)Test d'indépendance (Khi^2)

```
              Cathorse
Catprice       Low Medium-low Medium-high High
  Low           67         35           6    0
  Medium-low    10         75          17    0
  Medium-High    1         45          57    1
  High           0          5          75   25
> chisq.test(contingenceprihors)

        Pearson's Chi-squared test

data:  contingenceprihors
X-squared = 369.23, df = 9, p-value < 2.2e-16
```

```
              CatEng
Catprice       Low Medium High
  Low           54     33   21
  Medium-low    38     50   14
  Medium-High    5     79   20
  High           0     40   65
> chisq.test(contingenceprieng)

        Pearson's Chi-squared test

data:  contingenceprieng
X-squared = 162.55, df = 6, p-value < 2.2e-16
```

```
              CatTorq
Catprice       Low Medium High
  Low           69     33    6
  Medium-low    28     61   13
  Medium-High    5     73   26
  High           0     53   52
> chisq.test(contingencepritorq)

        Pearson's Chi-squared test

data:  contingencepritorq
X-squared = 179.79, df = 6, p-value < 2.2e-16
```

```
              CatTime
Catprice       Low Medium High
  Low            4     39   65
  Medium-low     2     78   22
  Medium-High   21     77    6
  High          82     14    9
> chisq.test(contingencepritim)

        Pearson's Chi-squared test

data:  contingencepritim
X-squared = 296.09, df = 6, p-value < 2.2e-16
```

H0 : Le prix et la variable sont indépendants

H1 : Le prix et la variable sont dépendants

On réalise un test du khi^2 pour vérifier l'hypothèse d'indépendance entre les variables. On s'aperçoit que pour un niveau de confiance de 5% on rejette, pour chaque variable l'hypothèse d'indépendance car la p valeur est bien inférieur à 0.05.

2)Régression linéaire simple

On va tenter d'estimer notre modèle à l'aide d'une régression linéaire simple dans un premier temps.

```
> summary(lm1)

Call:
lm(formula = Y ~ X1)

Residuals:
     Min       1Q   Median       3Q      Max 
-1354551  -353538  -106638    45222  3830423 

Coefficients:
            Estimate Std. Error t value Pr(>|t|)    
(Intercept)  -729912     113137  -6.452 3.07e-10 ***
X1            262436      24490  10.716  < 2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 744500 on 417 degrees of freedom
Multiple R-squared:  0.2159,	Adjusted R-squared:  0.214 
F-statistic: 114.8 on 1 and 417 DF,  p-value: < 2.2e-16
```

Cette première régression a été effectué par rapport à la taille du moteur. On voit que la p valeur est très faible ce qui indique que la taille du moteur influence le prix. Cependant, le R^2 ajusté n'est que de 0.214 ce qui signifie que cette variable explique notre modèle qu'a 21,4%.

```
> summary(lm2)

Call:
lm(formula = Y ~ X2)

Residuals:
     Min       1Q   Median       3Q      Max 
-1827427  -301270   -90183   174060  2617703 

Coefficients:
              Estimate Std. Error t value Pr(>|t|)    
(Intercept) -1159352.3    66207.5  -17.51   <2e-16 ***
X2              2672.3      103.5   25.82   <2e-16 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 521700 on 417 degrees of freedom
Multiple R-squared:  0.6151,	Adjusted R-squared:  0.6142 
F-statistic: 666.4 on 1 and 417 DF,  p-value: < 2.2e-16
```

Pour cette deuxième régression, ci-dessus, la p valeur indique une nouvelle fois que la variable est influente dans le prix. Il s'agit de la puissance du moteur. Le R^2 ajusté est de 0.6142 ce qui signifie que cette régression explique le modèle à 61,42%.

```
> summary(lm3)

Call:
lm(formula = Y ~ X3)

Residuals:
     Min       1Q   Median       3Q      Max 
-2703117  -327061   -29518   270357  3143300 

Coefficients:
              Estimate Std. Error t value Pr(>|t|)    
(Intercept) -1246378.7    77855.0  -16.01   <2e-16 ***
X3              3207.3      140.4   22.84   <2e-16 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 560500 on 417 degrees of freedom
Multiple R-squared:  0.5557,	Adjusted R-squared:  0.5546 
F-statistic: 521.6 on 1 and 417 DF,  p-value: < 2.2e-16
```

Pour le couple, la p valeur est aussi très faible et le R^2 ajusté est de 0.5546 ce qui indique que le modèle est expliqué à 55,46%

```
> summary(lm4)

Call:
lm(formula = Y ~ X4)

Residuals:
    Min      1Q  Median      3Q     Max 
-913869 -391646 -248176  140109 4120197 

Coefficients:
            Estimate Std. Error t value Pr(>|t|)    
(Intercept)  2377392     171511   13.86   <2e-16 ***
X4           -540662      46294  -11.68   <2e-16 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 729900 on 417 degrees of freedom
Multiple R-squared:  0.2465,	Adjusted R-squared:  0.2447 
F-statistic: 136.4 on 1 and 417 DF,  p-value: < 2.2e-16
```

Finalement, la quatrième variable explicative qui est le temps au 0-60 MPH influence le prix, mais le R^2 ajusté nous indique qu’elle n’estime le modèle qu’a 24,47%.

2)Régression linéaire multiple

On va tenter d‘estimer notre modèle à l‘aide d‘une régression linéaire multiple.

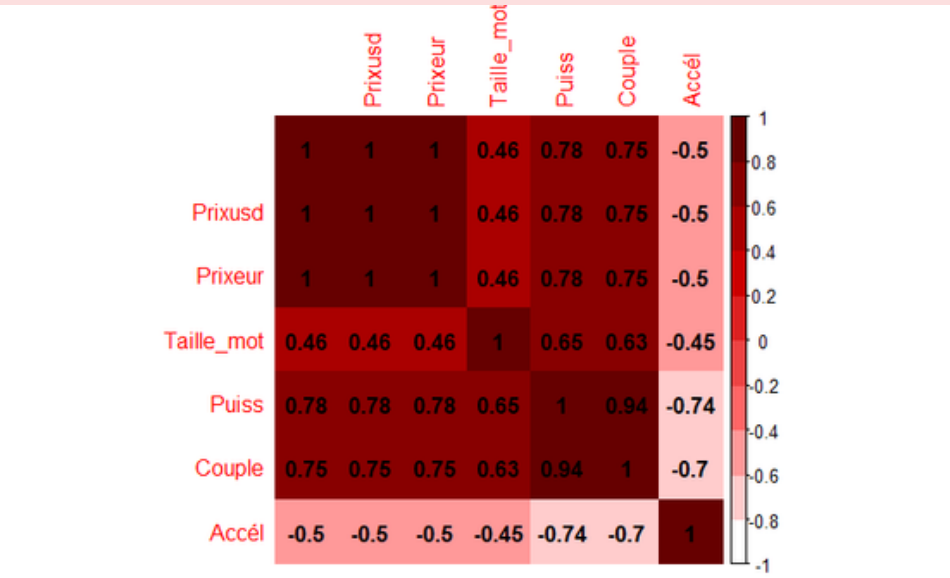

On voit dans un premier temps que la variable “prix” est plus ou moins corrélée avec les autres variables.

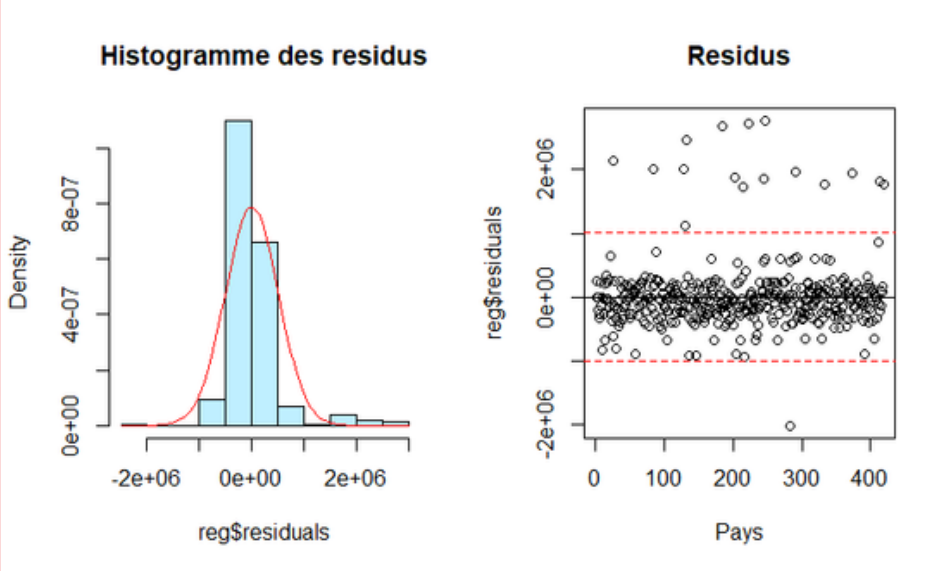


```
        Asymptotic one-sample Kolmogorov-Smirnov test

data:  reg$residuals[c(-133, -184, -223, -247, -282)]
D = 0.16251, p-value = 6.375e-10
alternative hypothesis: two-sided
```

D’après le test de Kolmogorov-Smirnov la p valeur est relativement faible ce qui indique que les résidus ne suivent pas une loi normale, ce à quoi on pouvait s’attendre car certain véhicule sont complètement à part. Le modèle aura donc du mal à approximer parfaitement.

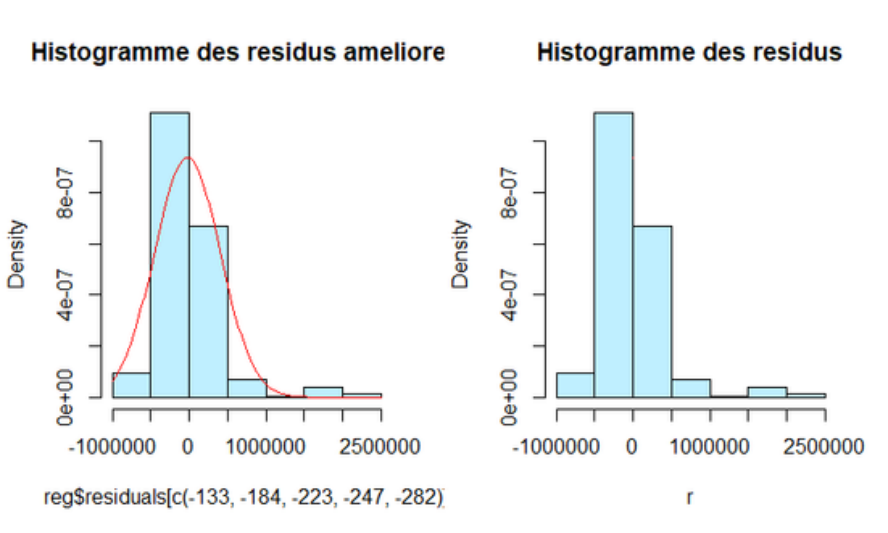

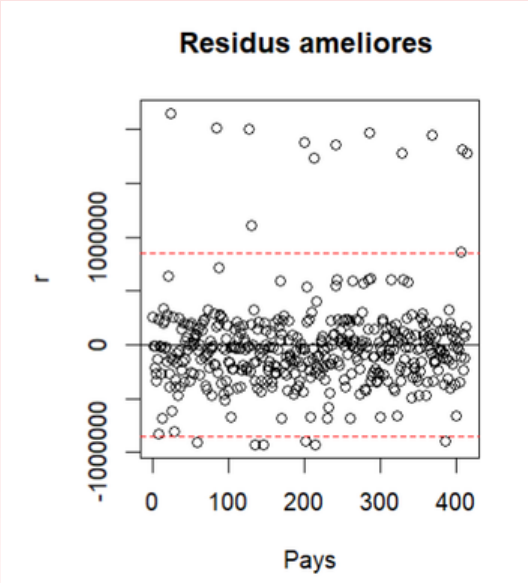

J’ai donc retiré les véhicules représentants les résidus les plus éloignés, pour un meilleur modèle.

```
> cbind(data.frame(result$which),result$adjr2,result$size)
        X1    X2    X3    X4 result$adjr2 result$size
X1   FALSE  TRUE FALSE FALSE    0.6141819           2
X1.1 FALSE FALSE  TRUE FALSE    0.5546471           2
X1.2 FALSE FALSE FALSE  TRUE    0.2446649           2
X1.3  TRUE FALSE FALSE FALSE    0.2140413           2
X2   FALSE  TRUE FALSE  TRUE    0.6281558           3
X2.1  TRUE  TRUE FALSE FALSE    0.6170542           3
X2.2 FALSE  TRUE  TRUE FALSE    0.6138642           3
X2.3 FALSE FALSE  TRUE  TRUE    0.5551117           3
X2.4  TRUE FALSE  TRUE FALSE    0.5536434           3
X2.5  TRUE FALSE FALSE  TRUE    0.3162380           3
X3    TRUE  TRUE FALSE  TRUE    0.6320624           4
X3.1 FALSE  TRUE  TRUE  TRUE    0.6281589           4
X3.2  TRUE  TRUE  TRUE FALSE    0.6169936           4
X3.3  TRUE FALSE  TRUE  TRUE    0.5541004           4
X4    TRUE  TRUE  TRUE  TRUE    0.6324302           5
```

A l’aide de cette matrice nous pouvons voir que le modèle le plus intéressant à retenir est celui avec X1, X2 et X4. C’est donc le mdèle que nous allons retenir qui a un R^2 ajusté de 0.632 ce qui signifie qu’il estime notre modèle à au moins 63,2%.

Conclusion

Pour conclure, le prix d‘un véhicule de sport va dépendre de chacune des variables que nous avons vu, mais certaines ne sont pas nécessaire pour modéliser l‘équation du prix en fonction des caractéristiques. Un passionné de voitures et particulièrement de voitures de sport prendra en compte ces caractéristiques et devra également prendre en compte le poids de la voiture qui est non négligeable au niveau de la performance. Un vendeur lui devra prendre en compte la couleur et le fait qu‘un acheteur de voiture de sport n‘est pas forcément un passionné et peut avoir eu l‘envie d‘acheter le véhicule pour son allure ou pour le constructeur associé à une image de marque que le client pourrait aimer.